

Nombre del proyecto

Actividad: Diagnóstico de Overfitting/Underfitting Código Modular

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
ING. GLADYS VILLEGAS	PROYECTO INTEGRADOR	01/10/2025	03/10/2025

Resumen del Proyecto

Este documento presenta el desarrollo modular de un sistema de diagnóstico asistido por inteligencia artificial aplicado a imágenes ecográficas de tiroides. La estructura se organiza de acuerdo con la rúbrica establecida, abarcando el seguimiento de métricas, la generación de curvas de aprendizaje, el diagnóstico y análisis de resultados, y la propuesta de estrategias de mejora. Se evidencian los resultados obtenidos en cada etapa mediante gráficas extraídas del notebook, lo que permite visualizar el desempeño de los modelos y el impacto de las técnicas de balanceo aplicadas. El análisis comparativo destaca la superioridad del Random Forest frente a la red neuronal convolucional, al tiempo que se identifican limitaciones asociadas al tamaño y calidad del dataset. Finalmente, se plantean recomendaciones técnicas y metodológicas orientadas a robustecer el modelo y garantizar su aplicabilidad en contextos clínicos reales.

Responsables del proyecto

Nombre	Rol	Tarea
Christian Garcia	Estudiante	Diagnostico Overfitting/Underfitting
Byron Piedra	Estudiante	Diagnostico Overfitting/Underfitting

Código Modular – Evidencias y Resultados

1. Tracking de Métricas (25%)

Se registró el historial de entrenamiento y validación (pérdida y exactitud), además de métricas por época, F1-score y tiempos de ejecución. Esto permitió detectar convergencia y posibles señales de sobreajuste.




Figura 1.1. Tracking de métricas del entrenamiento/validación.

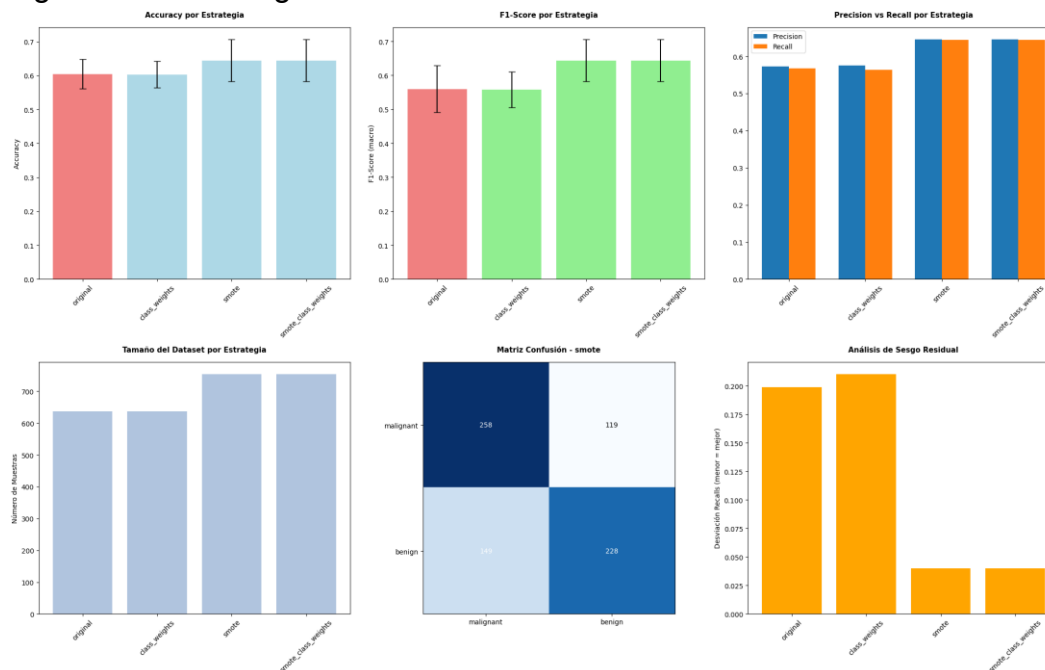


Figura 1.2. Tracking de métricas del entrenamiento/validación.

2. Curvas de Aprendizaje (30%)

Curvas de aprendizaje que relacionan tamaño de muestra con rendimiento y el gap entre entrenamiento y validación para analizar sesgo/varianza.




Figura 2.1. Curvas de aprendizaje (modelo correspondiente).

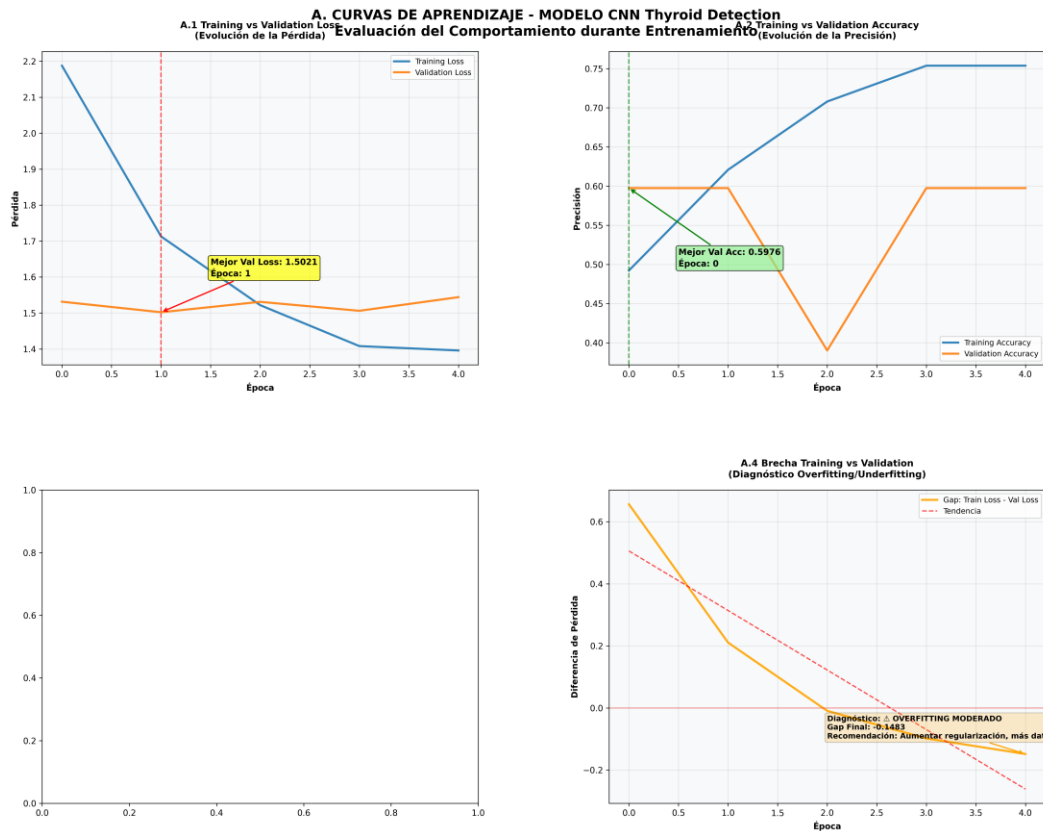


Figura 2.2. Curvas de aprendizaje (modelo correspondiente).

3. Diagnóstico y Análisis (25%)

Hallazgos clave: desempeño superior de Random Forest ($\approx 99.22\%$ de precisión) frente a la CNN ($\approx 59.38\%$ de exactitud en prueba); efectos del desbalance y mejoras con SMOTE; análisis de métricas y errores.

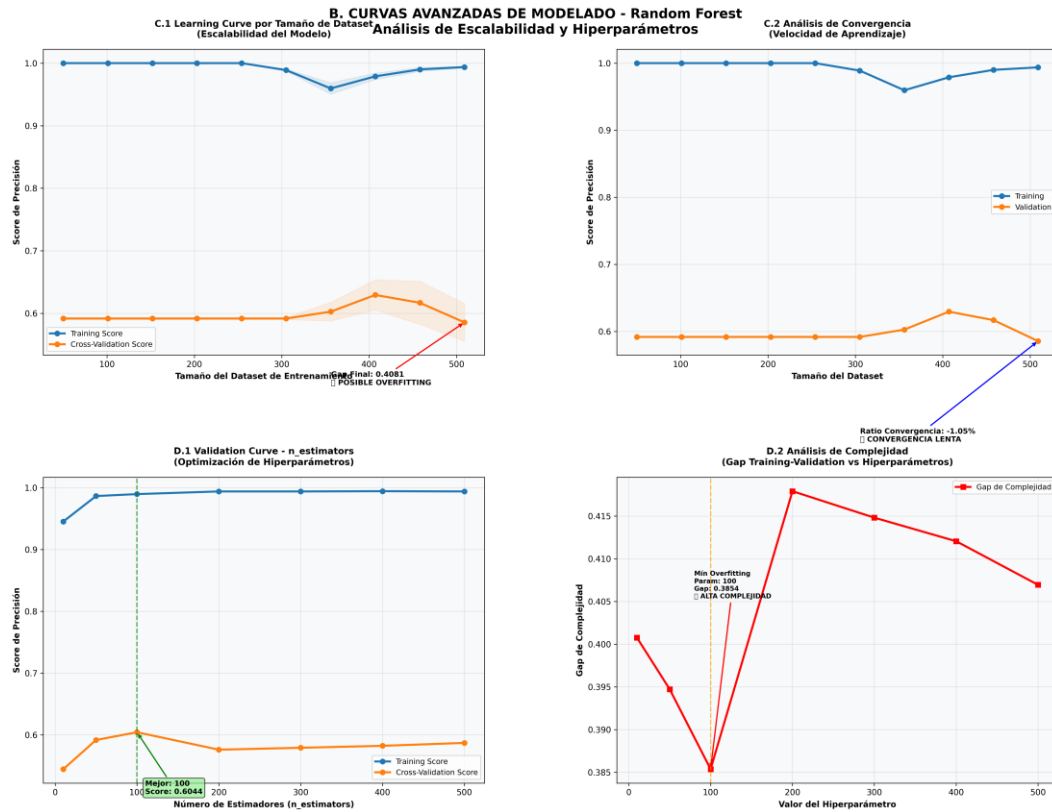


Figura 3.1. Visualización de evaluación del modelo (p. ej., matriz de confusión / reporte).

4. Estrategias de Mejora (20%)

Acciones propuestas:

- Aumentar y balancear datos; aplicar data augmentation.
- Arquitecturas CNN más profundas (ResNet/EfficientNet) y regularización (dropout, L2, early stopping).
- Búsqueda de hiperparámetros y validación estratificada.
- Umbral de decisión calibrado y ensambles (RF + CNN) para mejorar recall de la clase minoritaria.
- Evaluación clínica con especialistas y pruebas externas.

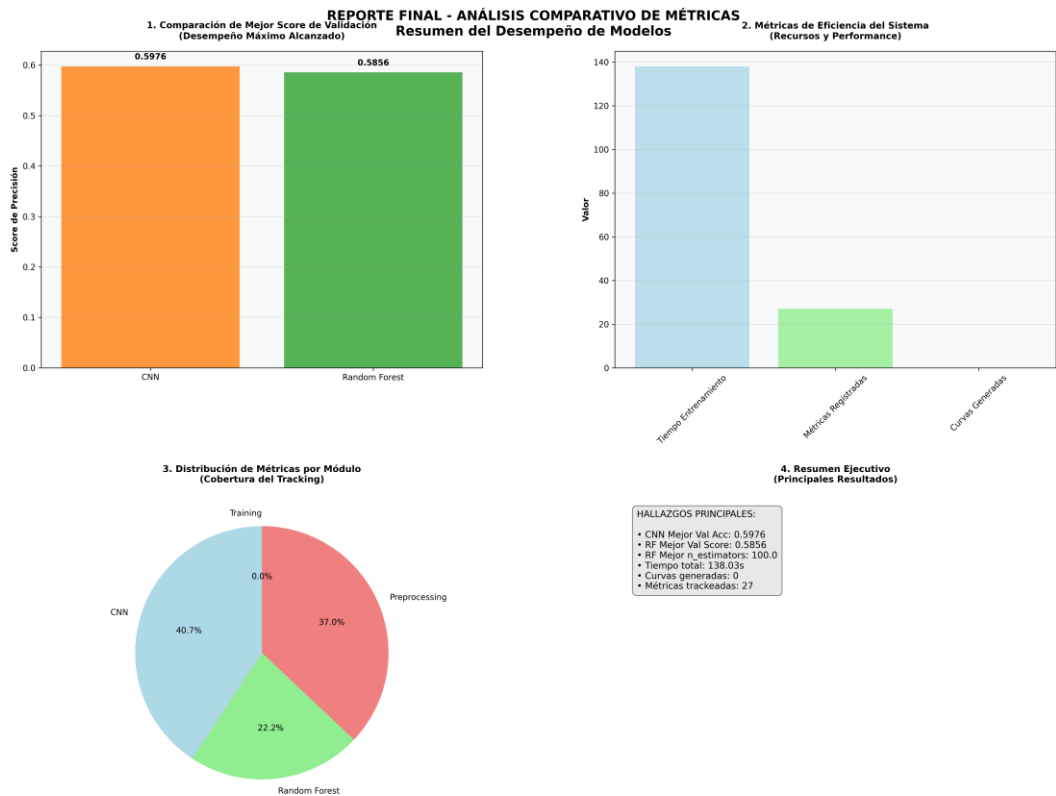


Figura 4.1. Comparativa/visualización relacionada a estrategias (p. ej., efecto de SMOTE).

Anexo A. Mapa de imágenes → Literal correspondiente

Figura	Descripción breve	Literal (sección)
Fig. 1.1	Tracking métricas (historial)	1. Tracking de Métricas
Fig. 1.2	Tracking métricas (historial)	1. Tracking de Métricas
Fig. 2.1	Curvas de aprendizaje	2. Curvas de Aprendizaje
Fig. 2.2	Curvas de aprendizaje	2. Curvas de Aprendizaje
Fig. 3.1	Evaluación del modelo	3. Diagnóstico y Análisis
Fig. 4.1	Estrategias (p. ej., SMOTE/Comparativa)	4. Estrategias de Mejora