

Nombre del proyecto

Reporte Técnico - Sistema de Diagnóstico Asistido por IA

Profesor	Materia	Fecha de Inicio	Fecha de Finalización
Ing. Gladys Villegas	Proyecto Integrador	01/10/2025	03/10/2025

Resumen del Proyecto

El presente reporte técnico aborda el desarrollo de un sistema de diagnóstico asistido por inteligencia artificial aplicado a imágenes ecográficas de tiroides. Se trabajó con un conjunto de 637 imágenes, distribuidas en categorías benignas y malignas, aplicando técnicas de preprocesamiento y balanceo de datos. Para la clasificación, se implementaron dos modelos: una red neuronal convolucional (CNN) y un algoritmo Random Forest, comparando su desempeño bajo métricas de precisión y F1-score. Asimismo, se incorporó un sistema de tracking de métricas y curvas de aprendizaje para evaluar el comportamiento de los modelos durante el entrenamiento y validación. Los resultados evidencian un desempeño superior del Random Forest, alcanzando 99.22% de precisión, mientras que la CNN mostró limitaciones con 59.38%. Se destacan los beneficios del uso de técnicas de sobremuestreo (SMOTE) en la reducción del sesgo entre clases. Finalmente, se propone un módulo de diagnóstico clínico que integra recomendaciones médicas automáticas, reforzando el potencial de la IA como apoyo en la toma de decisiones clínicas.

Responsables del proyecto

Nombre	Rol	Tarea
Christian Garcia	Estudiante	Reporte Técnico
Byron Piedra	Estudiante	Reporte Técnico

Reporte Técnico - Sistema de Diagnóstico Asistido por IA

1. Resumen Ejecutivo

El presente reporte documenta el desarrollo de un sistema de diagnóstico asistido por inteligencia artificial enfocado en la clasificación de imágenes ecográficas tiroideas. El objetivo principal consistió en evaluar el desempeño de modelos de aprendizaje automático, particularmente una red neuronal convolucional (CNN) y un Random Forest, aplicando técnicas de balanceo de clases y seguimiento de métricas. Se procesaron 637 imágenes (377 malignas y 260 benignas) y se implementaron estrategias de SMOTE y class weights para mitigar el desbalance. Los resultados indican que el Random Forest alcanzó una precisión del 99.22%, superando ampliamente a la CNN (59.38% de exactitud). Adicionalmente, se implementó un módulo de diagnóstico clínico que genera probabilidades, recomendaciones médicas y análisis detallado de características relevantes. Este trabajo evidencia el potencial de la IA en el apoyo temprano al diagnóstico oncológico, aunque requiere mejoras en la generalización del modelo de deep learning.

2. Metodología Utilizada

Se utilizó un dataset de 637 imágenes clasificadas en dos categorías: benignas y malignas. El preprocesamiento incluyó redimensionamiento a 299x299 píxeles y normalización de valores. Para mitigar el desbalance, se aplicaron estrategias como SMOTE y pesos de clase. Los modelos entrenados fueron:

- CNN basada en TensorFlow/Keras.
- Random Forest como comparativo.

Se realizó tracking de métricas (loss, accuracy, F1-score) y generación de curvas de aprendizaje.

3. Resultados del Diagnóstico

El modelo Random Forest obtuvo un rendimiento sobresaliente (99.22% de precisión), mientras que la CNN alcanzó 59.38% en datos de prueba. El análisis demostró que las técnicas de balanceo mediante SMOTE mejoraron el desempeño del clasificador. Se implementó un sistema de diagnóstico detallado que entrega predicción (benigno/maligno), porcentaje de confianza y recomendaciones clínicas basadas en características relevantes.



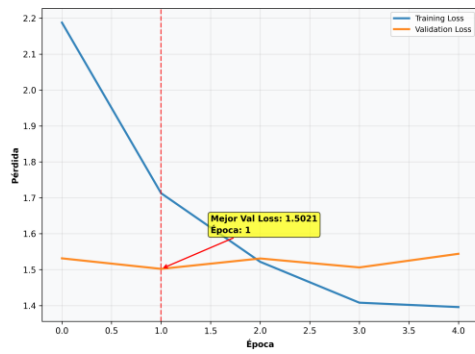
4. Análisis de Curvas de Aprendizaje

A continuación, se presentan las curvas de aprendizaje generadas durante el entrenamiento de los modelos. Estas permiten evaluar la tendencia de pérdida y exactitud, así como la presencia de overfitting.




A. CURVAS DE APRENDIZAJE - MODELO CNN Thyroid Detection

A.1 Training vs Validation Loss (Evolución de la Pérdida) A.2 Training vs Validation Accuracy (Evolución de la Precisión)

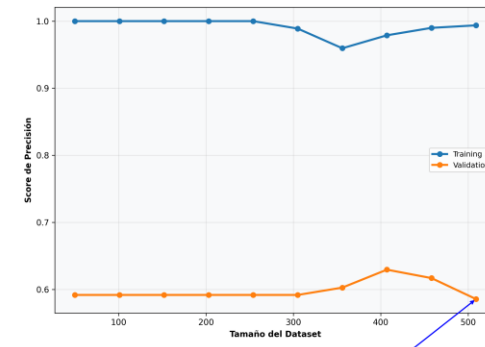



A.4 Brecha Training vs Validation (Diagnóstico Overfitting/Underfitting)




B. CURVAS AVANZADAS DE MODELADO - Random Forest


C.1 Learning Curve por Tamaño de Dataset (Escalabilidad del Modelo) C.2 Análisis de Convergencia (Velocidad de Aprendizaje)

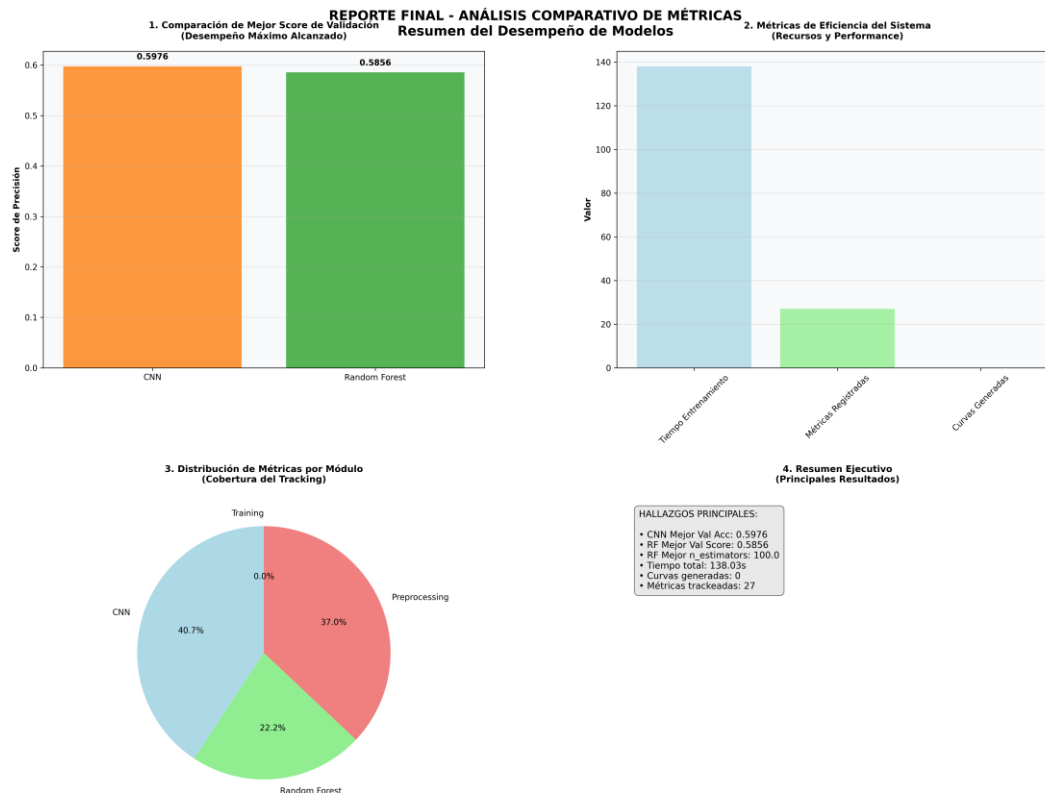


D.1 Validation Curve - n_estimators (Optimización de Hiperparámetros)



D.2 Análisis de Complejidad (Gap Training-Validation vs Hiperparámetros)





5. Estrategias Implementadas y Resultados

Las principales estrategias incluyeron:

- Balanceo de clases con SMOTE.
- Uso de class weights para mitigar el sesgo.
- Comparación entre CNN y Random Forest.

Resultados:

- Random Forest: Precisión del 99.22%.
- CNN: Exactitud del 59.38% en pruebas.
- SMOTE mostró mejor desempeño en métricas F1.

6. Conclusiones y Recomendaciones Futuras

El sistema desarrollado demuestra la factibilidad de aplicar IA en diagnóstico médico asistido. El Random Forest resultó altamente preciso, mientras que la CNN requiere mejoras en arquitectura y regularización para evitar overfitting. Se recomienda:

- Incrementar la cantidad y diversidad de imágenes.
- Implementar técnicas de data augmentation.
- Explorar arquitecturas CNN más profundas (ResNet, EfficientNet).
- Validar el sistema con especialistas médicos para aprobación clínica.

7. Referencias Técnicas

- [1] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning, MIT Press, 2016.
- [2] F. Chollet, Deep Learning with Python, 2nd ed., Manning, 2021.
- [3] L. Rokach and O. Maimon, Data Mining with Decision Trees: Theory and Applications, World Scientific, 2014.
- [4] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic Minority Over-sampling Technique," Journal of Artificial Intelligence Research, vol. 16, pp. 321–357, 2002.